Свёртка изображений с использованием дискретной GPU и в конвейере CPU+GPU

Михаил Тупчий 24.Б41

СПбГУ

09.10.2026

Введение и методология замеров

Цель: оценить ускорение свёртки с использованием дискретной видеокарты и совместную обработку набора изображений на CPU и GPU.

- 25 измерений; прогревы исключены.
- Время обработки папки в данной работе замеряются от старта чтения первого файла до записи последнего обработанного файла.

Вопросы исследования:

1. Позволяет ли наивное использование GPU получить прирост производительности?
2. Повышает ли совместное использование CPU и GPU общую скорость?

Постановка эксперимента

Аппаратная платформа

- CPU: Intel Core i5-12450H, 8 ядер / 12 потоков.
- GPU: дискретная RTX 3060 Laptop, 6 ГБ VRAM; одно CUDA-устройство.

Программная реализация

- ILGPU: Для работы с видеокартой.
- Собственная свёртка.

Тестовый набор

- 100 изображений JPEG, 3840×2160.

Исследуемые подходы

1. CPU: Вложенный параллелизм по строкам.
2. Микробенчмарки CPU и GPU.
3. Последовательный цикл по файлам на GPU.
4. Конвейер Гибридный: GPU, CPU + GPU.

Анализ 1: BenchmarkDotNet

Одно изображение в памяти, BoxBlur 3×3, без чтения и записи файлов.

	512×512		1024×1024	
Метод	Mean, мс	КиБ	Mean, мс	КиБ
CPU последовательно	2.616	256.4	10.102	1026.0
CPU по строкам	0.637	260.3	2.132	1042.6
CPU по столбцам	0.793	260.1	2.360	1042.0
ImageSharp с преобразованиями	2.818	269.4	10.031	1039.3
GPU: передача, ядро, возврат	0.478	256.4	0.642	1025.2
GPU: ядро + ожидание	0.053	0	0.117	0

Mean — среднее время одного вызова. КиБ — управляемые выделения на вызов, не вся память и не VRAM. Прогревы исключены.

Результат сравнения

На 1024×1024: GPU полный — 0.642 мс, CPU-строки — 2.132 мс по Mean.

Анализ 2: Пакетная обработка на GPU

GPU-наивный — 17.88с без профиля.

Медианы полных вызовов, 25 измерений.

Отдельная диагностика с профилем: вся папка — 17.93с.

Стадия	Медиана суммы, с
Чтение + декодирование + перевод в серый	9.47
Передача ОЗУ → GPU + синхронизация	0.44
Запуск + ядро GPU + синхронизация	0.38
Возврат GPU → ОЗУ + массив результата	0.53
Подготовка результата + кодирование + сохранение	6.96

Синхронизация — ожидание завершения GPU-работы.

Агентная архитектура (Гибридный Конвейер)

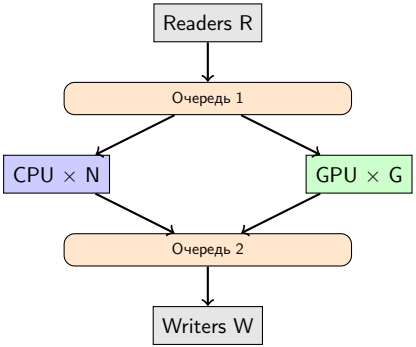

Механизмы и логика:

- Читатель декодирует изображения. Каждый файл получает один вычислитель.
- Агенты CPU и GPU параллельно забирают декодированные изображения из Очереди 1 и считают свёртку.
- Писатель подготавливает результат, кодирует и сохраняет файл.
- Читатели и писатели настраиваются отдельно.

GPU-конвейер: где возникает очередь

100 файлов; 2 GPU-агента; профиль включён. Время в секундах.

Читатели / писатели	Полное время	Ждут вход	Ждут выход
1 / 1	9.73	18.06	< 0.01
1 / 2	9.83	18.22	< 0.01
2 / 1	7.28	1.11	11.57
2 / 2	5.60	10.03	< 0.01
3 / 3	4.07	6.98	< 0.01

Что измеряют таймеры. Вход — получение подготовленного изображения из очереди, выход — помещение результата в очередь к писателям. При пустом входе или полном выходе агент ждёт.

Вывод: при 2/1 результаты ждут писателя, при 1/2 агенты ждут читателя. При 3/3 время меньше.

Анализ 3: Повышает ли гибридная модель производительность?

Медианы полного времени, с; по 25 прогонов на конфигурацию, без профиля.

CPU-агенты	GPU-агенты	R1/W1	R2/W2	R3/W3	R5/W5	R6/W6
0	2	9.71	5.50	4.39	3.22	**2.95**
0	3	—	—	—	—	3.43
0	4	—	—	—	—	3.53
4	2	9.97	6.41	4.75	—	—
4	4	9.90	5.82	4.71	—	—
2	4	9.92	5.56	4.53	**3.53**	—
6	2	9.93	5.86	5.03	—	—
6	4	10.14	6.51	5.67	—	—
6	6	12.01	5.76	4.74	—	—

R/W — число читателей/писателей.

Итоговое сравнение всех архитектур

100 JPEG 4K; 25 измерений; лучшие проверенные конфигурации.

Подход	Лучшая проверенная конфигурация	Медиана, с
CPU: Наивная папка	Файлы по одному	24.40
CPU: внешний цикл	Параллелизм по файлам	4.50
CPU: строки	Параллелизм по строкам	4.28
CPU: столбцы	Параллелизм по столбцам	5.17
ImageSharp	Библиотечная свёртка	9.02
CPU-агенты	4 вычислителя, R4/W4	4.21
Наивная GPU-папка	Последовательная на GPU	17.88
GPU-конвейер	0 CPU + 2 GPU, R6/W6	2.95
Гибридный CPU+GPU	2 CPU + 4 GPU, R5/W5	3.53

Общие выводы

1. Позволяет ли наивное использование GPU получить прирост производительности?

- Да. Последовательная GPU-папка быстрее последовательной CPU-папки: 17.88 против 24.40с.

2. Повышает ли совместное использование CPU и GPU общую скорость?

- Гибридный конвейер CPU + GPU обработал папку за 3,53 с — быстрее лучшего варианта только на CPU 4,21 с. Но лучшим среди проверенных оказался GPU-конвейер без CPU агентов свёртки — 2,95 с.

Спасибо за внимание!